

第 2 讲：词表示

单隐藏层 MLP 版朴素 CBOW 与静态词向量反思

高展沛 (2023212036)


1 课堂任务：单隐藏层 CBOW

给定语料 $w_1, \dots, w_T$, 窗口半径 c , CBOW 用上下文 $C_t = \{w_{t-c}, \dots, w_{t-1}, w_{t+1}, \dots, w_{t+c}\}$ 预测中心词 w_t , 最大化 $\sum_t \log p_\theta(w_t | C_t)$ 。单隐藏层 MLP 的前向计算为

$$x_t = \frac{1}{|C_t|} \sum_{w \in C_t} E[w], \quad h_t = \tanh(W_h x_t + b_h),$$

$$p(w_t | C_t) = \text{softmax}(W_o h_t + b_o), \quad \mathcal{L}_t = -\log p(w_t | C_t).$$

这里 E 既是输入查表矩阵, 也是最终学习到的词表示。隐藏层的作用不是炫技, 而是让平均上下文向量经过一次非线性重组, 表达“多个上下文词共同指向一个中心词”的组合模式。



Algorithm 1: One-Hidden-Layer CBOW 训练流程

Input: 分词语料 $D = [w_1, \dots, w_T]$, 窗口半径 c , 词表 V , 维度 d, m , 学习率 η
Output: 词向量矩阵 E 与 MLP 参数 $\Theta = \{W_h, b_h, W_o, b_o\}$

- 1 建立 word_to_id, 将语料映射为 id 序列
- 2 初始化 $E \in \mathbb{R}^{|V| \times d}$, W_h, b_h, W_o, b_o
- 3 **for** $epoch = 1$ **to** K **do**
- 4 打乱所有合法中心位置 t
- 5 **foreach** 中心位置 t **do**
- 6 $C_t \leftarrow$ 收集窗口内所有非中心词 id
- 7 **if** C_t 为空 **then**
- 8 跳过该样本
- 9 **end**
- 10 $x_t \leftarrow |C_t|^{-1} \sum_{i \in C_t} E[i]$ // 上下文平均
- 11 $h_t \leftarrow \tanh(W_h x_t + b_h)$
- 12 $p_t \leftarrow \text{softmax}(W_o h_t + b_o)$
- 13 $\mathcal{L} \leftarrow -\log p_t[\text{id}(w_t)]$
- 14 对 $\mathcal{L}$ 反向传播, 更新 E, W_h, b_h, W_o, b_o
- 15 **end**
- 16 输出平均 loss, 用于观察训练是否收敛
- 17 **end**
- 18 返回 E ; 若改为 Skip-Gram, 则输入中心词并逐个预测上下文词

2 实现检查点

环节	容易出错处	检查方式
样本构造	窗口越界、中心词混入上下文	打印前 5 个 (C_t, w_t) 人工核对
池化	padding 位置被平均进去	使用 mask mean, 分母只数有效词
softmax	目标 id 与词表 id 错位	用玩具词表检查最高概率词
反传	embedding 未更新或共享失败	观察同一词多次出现时梯度累加
训练日志	loss 下降但近邻无意义	同时看 loss 与近邻词质量

完整 softmax 下, 每个样本输出层复杂度约为 $O(|V|m)$, 因此它适合作为课堂基线而不是大词表工业方案。若改成 mini-batch, 实现上只需把多个 C_t padding 到同一长度, 并用 mask 求平均; 算法本质仍是“上下文汇聚 $\rightarrow$ 隐层变换 $\rightarrow$ 预测中心词”。

3 探索: CBOW/Skip-GRAM 的局限

问题	根因	解决方向
完整 softmax 昂贵	每步要归一化全词表 $ V $	negative sampling、hierarchical softmax
高频词支配	高频共现不等于语义信息量	subsampling、tf-idf 或 PMI 重加权
OOV 与低频词差	词被看作不可拆原子	fastText、字符 n-gram、中文字词融合
一词多义	一个词只有一个静态向量	ELMo/BERT/GPT 上下文化表示
词序信息弱	CBOW 平均池化抹掉顺序	位置编码、RNN、Transformer
长距离依赖弱	固定窗口只建模局部共现	全句 encoder、文档级记忆

4 从朴素模型到现代表示

完整 softmax 的概率为

$$p(w | h) = \frac{\exp(u_w^\top h)}{\sum_{v \in V} \exp(u_v^\top h)}.$$

当 $|V|$ 很大时, 训练瓶颈集中在分母。negative sampling 将问题改写为“真实共现对”和“噪声词对”的二分类, 使每个样本只更新少量输出向量; hierarchical softmax 则用 Huffman 树把一次 $|V|$ 分类压成 $O(\log |V|)$ 次路径判别。二者解决的是算力问题, 不直接解决语义表达问题。

更深的缺陷来自静态表示: CBOW 学到的是“一个词在总体语料中平均是什么意思”, 却不能区分“苹果发布新机”和“吃苹果”中的不同语义。subword 让新词可组合, 上下文化模型让同一词在不同句子中产生不同向量:

$$z_t = f(w_1, \dots, w_t, \dots, w_n).$$

这说明词表示的真正升级路线是从局部共现统计走向动态上下文建模。

创新性判断

CBOW/Skip-GRAM 不是过时玩具, 而是一个极简“语义压缩机”: 把窗口证据压进向量, 再用向量恢复目标词。突破点应沿三条轴展开: 训练目标更高效、词形表示更可泛化、语义表示更上下文化。第 5 讲的 RNN-NER 正是这条路线的下一步: 词不再只有全局平均含义, 而要在当前序列位置上被重新解释。

5 完成物与验收

本作业完整材料包括算法伪代码、问题分析、扩展方案和本报告。若要把伪代码落成工程, 最小验证应包括: 构造玩具语料检查 loss 是否下降; 抽取近邻词检查语义聚类; 对比完整 softmax 与负采样的训练速度; 加入 OOV 测例检查 subword 是否优于纯词表查表。这样能把课堂算法、探索问题和工程验证闭成一条证据链。

升级实验	预期改善	失败时的诊断
负采样	单步训练更快, 大词表可扩展	采样分布过偏, 高频负样本过多
subword	未登录词和低频词近邻更合理	字符片段太短, 语义噪声变大
上下文化 encoder	多义词在不同句中分离	数据太少或任务不需要复杂上下文

因此, 本题的“突破”不应理解为把朴素 CBOW 包装得更复杂, 而是明确它在哪些假设下有效、在哪些语言现象前必然失效, 并给出可验证的升级路线。

6 方法取舍矩阵

方法	最适合解决的问题	主要代价或风险
朴素 CBOW	快速建立静态语义空间, 解释性强	平均池化丢词序, 无法处理多义词
Skip-GRAM	低频词样本更充分	样本数变多, 训练更慢
负采样	大词表训练速度	负样本分布会改变表示偏好
GloVe/PMI	显式利用全局共现统计	需要构造较大共现矩阵
Transformer 表示	多义词和长距离语境	模型重、可解释性下降, 需要更多数据

最后的课程结论可以压缩为一句话: CBOW/Skip-GRAM 给出的是“词的默认含义”, 而现代 NLP 更需要“词在当前语境中的临时含义”。从这个角度看, 第 2 讲并不是孤立的词向量练习, 而是在为后续 RNN、Seq2Seq 与预训练语言模型建立共同的表示学习入口。