

第 2 讲：词表示

单隐藏层 MLP 版朴素 CBOW 与静态词向量反思

高展沛
2026 年 6 月

1 课堂任务：朴素 CBOW

给定语料 $w_1, \dots, w_T$ ，窗口半径 c ，CBOW 用中心词两侧上下文 $C_t = \{w_{t-c}, \dots, w_{t-1}, w_{t+1}, \dots, w_{t+c}\}$ 预测 w_t ：


$$\max_{\theta} \sum_t \log p_{\theta}(w_t | C_t).$$

单隐藏层 MLP 结构如下：

$$x_t = \frac{1}{|C_t|} \sum_{w \in C_t} E[w], \quad h_t = \tanh(W_h x_t + b_h),$$

$$p(w_t | C_t) = \text{softmax}(W_o h_t + b_o), \quad \mathcal{L}_t = -\log p(w_t | C_t).$$

其中 E 是词向量矩阵，也是训练结束后要保存的表示。



手写伪代码

1. 建立词表，把语料转成 id 序列。
2. 对每个位置 t ，收集窗口内非中心词 id，组成训练样本 (C_t, w_t) 。
3. 查表得到 $E[C_t]$ ，对上下文向量求平均得到 x_t 。
4. 计算 $h_t = \tanh(W_h x_t + b_h)$ 与 $p = \text{softmax}(W_o h_t + b_o)$ 。
5. 用交叉熵对目标词 w_t 求损失，反向传播更新 E, W_h, b_h, W_o, b_o 。
6. 每轮输出平均 loss；训练结束保存 E 作为词表示。

Skip-Gram 只把预测方向反过来：输入中心词 w_t ，逐个预测窗口上下文 w_j 。CBOW 训练快、对高频模式稳定；Skip-Gram 样本更多，通常对低频词更友好。

2 探索：问题与解决

问题	原因	解法
完整 softmax 昂贵	每步归一化全词表 V	negative sampling / hierarchical softmax
高频词支配	共现次数不等于信息量	subsampling / tf-idf 式重加权
OOV 与低频词差	词被当作不可拆原子	fastText/subword/字符 n-gram
一词多义	一个词只有一个静态向量	ELMo/BERT 上下文文化表示
长距离依赖弱	固定窗口只看局部	RNN/Transformer 全句建模
词序信息弱	CBOW 平均池化丢顺序	位置编码、序列模型、注意力

核心判断

CBOW/Skip-Gram 的历史价值是把离散符号放入连续语义空间；它们的根本局限是把语义压成“静态词点”。突破方向不是简单堆深 MLP，而是让表示沿三条线进化：从局部窗口到全局统计，从词级原子到子词组合，从静态向量到上下文文化动态表示。

3 创新性总结

本作业把词表示学习理解成“压缩与恢复”的过程：CBOW 把窗口上下文压缩为一个向量，再用它恢复中心词。若恢复失败，错误通常不是某个词孤立造成的，而是采样、词表、语义歧义和上下文范围共同造成的。因此，一个更现代的路线应是：先用负采样和低频词控制提高可训练性，再用 subword 解决泛化，最后用 Transformer/RNN 让同一个词在不同语境中拥有不同表示。这也自然引出第 5 讲的序列标注：词向量只是起点，真正的实体判断必须回到上下文中完成。