

第 5 讲：RNN 命名实体识别

从单向序列状态到多粒度上下文融合

高展沛 (2023212036)

1 任务：RNN-NER

命名实体识别输入句子 $x_1, \dots, x_n$ ，输出同长度 BIO 标签 $y_1, \dots, y_n$ ，例如 B-PER/I-PER/B-ORG/I-ORG/O。单向 RNN 基线把左侧历史写入隐状态：

$$h_t = \tanh(W_x E[x_t] + W_h h_{t-1} + b), \quad s_t = W_y h_t + b_y,$$
$$p(y_t | x_{\leq t}) = \text{softmax}(s_t), \quad \mathcal{L} = \frac{1}{n} \sum_t -\log p(y_t^* | x_{\leq t}).$$

它是最小可解释模型：embedding 负责词语含义，RNN 状态负责历史上下文，线性层负责把状态映射到标签空间。

Algorithm 1: 基于 RNN 的 NER 训练、解码与评测

Input: 标注语料 $\mathcal{S} = \{(x_{1:n}, y_{1:n})\}$ ，token 词表，BIO 标签表，学习率 η
Output: RNN-NER 参数与实体级 Precision/Recall/F1

```
1 初始化 embedding  $E$ 、RNN 参数  $W_x, W_h, b$ 、分类器  $W_y, b_y$ 
2 for  $epoch = 1$  to  $K$  do
3   打乱训练句子
4   foreach 句子  $(x_{1:n}, y_{1:n})$  do
5      $h_0 \leftarrow \mathbf{0}$ ,  $\mathcal{L} \leftarrow 0$ 
6     for  $t = 1$  to  $n$  do
7        $e_t \leftarrow E[\text{id}(x_t)]$ 
8        $h_t \leftarrow \tanh(W_x e_t + W_h h_{t-1} + b)$  // 左上下文递推
9        $s_t \leftarrow W_y h_t + b_y$ ,  $p_t \leftarrow \text{softmax}(s_t)$ 
10       $\mathcal{L} \leftarrow \mathcal{L} - \log p_t[y_t]$ 
11    end
12    对  $\mathcal{L}/n$  反向传播并更新参数
13  end
14 end
15 推理时逐词取  $\arg \max p_t$ ，再修复非法 BIO 转移
16 将 BIO 序列转换为实体 span，按完全匹配计算 Precision/Recall/F1
```

若出现 O I-ORG 或 B-PER I-LOC，说明逐词 softmax 缺少标签结构约束；这正是后续 CRF 解码要解决的问题。

2 基线诊断


错误类型	例子	暴露的问题
边界断裂	B-ORG O I-ORG	逐词分类没有全局 span 意识
类型漂移	B-PER I-LOC	标签转移未约束实体内部一致性
右侧缺失	“苹果发布新机”	单向 RNN 当前位点看不到后文
OOV 实体	“某某科技园”	纯词 embedding 无法利用后缀形态

训练时最小日志应包含 loss、token accuracy 和实体级 F1。若 token accuracy 高但实体 F1 低，通常说明模型学会了大量 O 标签，却没有稳定识别完整实体边界。

张量	形状	含义
token ids	$[n]$ 或 $[B, n]$	原句 token 的整数编号，padding 位置需 mask
embedding	$[n, d]$	每个 token 的词向量或词 + 字符拼接向量
hidden states	$[n, h]$	RNN 对每个位置累积出的上下文状态
emission scores	$[n, L]$	每个位置到 L 个 BIO 标签的发射分数
entity spans	$(l, r, type)$	评测时真正关心的实体级输出

3 探索：如何同时利用上下文

单向 RNN 的缺陷是当前位置只能直接看到左侧历史。实体类型常由左右词共同决定，例如“苹果发布新机”中的“苹果”偏组织，“买了苹果”偏普通名词。更强模型应同时利用四类上下文：字符形态、左右句内语境、标签转移结构和文档实体历史。



推荐基线升级为 BiLSTM/GRU + CRF:

$$z_t = [e_t^{word}; e_t^{char}], \quad \vec{h}_t = RNN_f(z_t, \vec{h}_{t-1}), \quad \overleftarrow{h}_t = RNN_b(z_t, \overleftarrow{h}_{t+1}),$$
$$o_t = [\vec{h}_t; \overleftarrow{h}_t], \quad score(x, y) = \sum_t s_t[y_t] + \sum_t A[y_{t-1}, y_t].$$

其中 A 学习标签转移规律，Viterbi 在整句上搜索全局最优 BIO 序列。字符特征能处理未登录词和实体后缀，如“大学、公司、集团、省、市、路”；CRF 则阻止非法边界。

上下文来源	捕获的信息	对 NER 的作用
字符/子词	词形、后缀、中文构词	缓解 OOV，识别机构/地点模式
双向句内状态	左右搭配与句法线索	消歧实体类型，定位边界
CRF 标签转移	BIO 合法性与类型一致性	避免局部最优标签序列
文档级记忆	别名、简称、跨句复现	解决长距离指代和简称实体

4 突破方案：多粒度上下文记忆

文档级增强可维护实体记忆表：保存高置信实体字符串、类型分布、别名和最近出现位置。当前 token 的句内表示 o_t 与记忆表示 m_t 通过门控融合：

$$g_t = \sigma(W_g[o_t; m_t] + b_g), \quad r_t = g_t \odot o_t + (1 - g_t) \odot m_t.$$

当句内证据强时模型依赖 o_t ，当当前句子模糊时调用 m_t 。若算力允许，可用中文 BERT/MacBERT 替代 BiLSTM encoder，再保留 CRF 作为结构化解码层；这样既吸收大规模预训练语义，又不放弃 BIO 约束。

最终判断

CBOW 学的是“词通常和谁共现”，NER 要判断“词此刻在上下文中扮演什么角色”。强 NER 系统必须让词表示被字符形态、左右语境、标签结构和文档历史共同校正。验证时除实体级 F1 外，还应单独报告 OOV 实体 F1 与跨句别名 F1，确认新增上下文确实发挥作用。

5 完成物与验收

本作业给出 RNN-NER 伪代码、BIO 解码规则、BiLSTM-CRF 方案和文档记忆扩展。最小工程验证应包括：构造含非法 BIO 的样例检查修复规则；比较单向 RNN 与 BiRNN 的实体级 F1；加入字符特征后测试 OOV 实体；加入文档记忆后测试简称识别。这样能把“利用上下文”从口号落到可测指标上。

消融设置	应验证的能力	关键观察
RNN → BiRNN	是否需要右上下文	机构名、地点名边界应更完整
无 char → char	是否利用词形模式	OOV 实体 F1 应提升
softmax → CRF	是否利用标签结构	非法 BIO 与类型漂移应下降
无记忆 → 文档记忆	是否利用跨句线索	简称、别名实体召回应提升

最终系统不追求“模块最多”，而追求每个新增上下文来源都能被独立验证。只有当消融实验显示某类错误被真实压低时，复杂模型才算带来有效创新。

6 风险控制

风险	表现	控制办法
类别不均衡	模型倾向预测 0	实体级 F1、类别加权或采样重平衡
过拟合后缀	看到“公司”就预测机构	加入反例，结合上下文而非只看词形
记忆污染	错误实体进入文档记忆	只写入高置信 span，并设置衰减权重
预训练错配	BERT 特征强但边界不稳	顶层保留 CRF，按实体 span 调参

这份设计的突破性不在于堆叠名词，而在于给每一种上下文一个明确职责：字符处理未登录词，双向状态处理左右证据，CRF 处理标签结构，文档记忆处理跨句复现。职责清楚，实验才可复现。