

第 5 讲：RNN 命名实体识别

从单向序列状态到多粒度上下文融合

高展沛
2026 年 6 月

1 课堂任务：RNN-NER 伪代码

命名实体识别输入句子 $x_1, \dots, x_n$ ，输出同长度 BIO 标签 $y_1, \dots, y_n$ 。单向 RNN 基线把左侧历史压入状态：

$$h_t = \tanh(W_x E[x_t] + W_h h_{t-1} + b), \quad s_t = W_y h_t + b_y,$$
$$p(y_t | x_{\leq t}) = \text{softmax}(s_t), \quad \mathcal{L} = \frac{1}{n} \sum_t -\log p(y_t^* | x_{\leq t}).$$

训练伪代码

1. 建 token 词表和 BIO 标签表，如 B-PER, I-PER, B-ORG, I-ORG, O。
2. 初始化 embedding、RNN 参数和线性分类器。
3. 对每个句子从左到右递推 h_t ，由 s_t 预测当前位置标签。
4. 对所有位置求交叉熵平均，调用反向传播更新参数。
5. 验证时把预测 BIO 序列转换为实体 span，按实体级 precision/recall/F1 评测。

解码伪代码

推理阶段逐词取 $\arg \max_y p(y_t)$ 得到初始标签；随后检查 BIO 合法性。若出现 O I-ORG 或 B-PER I-LOC 这类非法转移，可按规则改为 B-ORG 或置为 O。更好的做法是在顶层接 CRF，由 Viterbi 直接搜索全局合法最优序列。

2 为什么单向 RNN 不够

NER 不是孤立词分类。实体边界常由左右词共同决定，例如“苹果发布新机”中的“苹果”更像组织，而“买了苹果”中的“苹果”更像普通名词。单向 RNN 在位置 t 只能直接看到 $x_{\leq t}$ ，右侧证据要到未来才进入状态，当前标签判断天然滞后。同时，逐词 softmax 不知道标签之间的结构约束，容易输出局部高分但整体非法的 BIO 序列。

3 上下文增强方案


推荐的工程路线是 BiLSTM/GRU + 字符特征 + CRF：

$$z_t = [e_t^{\text{word}}; e_t^{\text{char}}], \quad \vec{h}_t = \text{RNN}_f(z_t, \vec{h}_{t-1}),$$
$$\overleftarrow{h}_t = \text{RNN}_b(z_t, \overleftarrow{h}_{t+1}), \quad o_t = [\vec{h}_t; \overleftarrow{h}_t].$$

CRF 分数为

$$\text{score}(x, y) = \sum_t s_t[y_t] + \sum_t A[y_{t-1}, y_t],$$

其中 A 学习标签转移规律，Viterbi 负责全局解码。



4 突破方案：多粒度上下文记忆

进一步的创新设计是加入文档级实体记忆。模型先抽取高置信实体，保存字符串、类型分布、别名和最近出现位置；后文遇到简称或歧义词时，把记忆向量与句内向量门控融合：

$$g_t = \sigma(W_g[o_t; m_t] + b_g), \quad r_t = g_t \odot o_t + (1 - g_t) \odot m_t.$$

当句内证据强时依赖 o_t ，当当前句子模糊时调用文档记忆 m_t 。若数据和算力允许，可把 BiLSTM encoder 替换为中文 BERT/MacBERT，再保留 CRF 作为结构化解码层。

最终判断

CBOW 学的是“词通常和谁共现”，NER 要判断“词此刻在上下文中扮演什么角色”。因此强 NER 系统必须同时利用字符形态、左右句内语境、标签转移约束和文档级实体历史；这比单向 RNN 更接近真实语言理解。